

Reference: 数值分析第五版 (李庆扬 王能超 易大义)

其实是一门很有深度的课程, 后悔还没认真学。

Episode 1 引论

数值问题

误差

有效数字

病态问题

技巧

Episode 2 插值

多项式插值

拉格朗日插值

牛顿插值

三次埃尔米特插值

分段插值

三次样条插值

Episode 3 逼近与拟合

线性空间

正交多项式

逼近

拟合

有理逼近、帕得逼近

Episode 4 数值微分和数值积分

机械求积

代数精度

插值形求积公式

牛顿-柯特斯公式

复合求积公式

梯形法递推化

外推技巧

高斯求积公式

高斯-勒让德求积公式

多重积分

数值微分

插值型求导公式

数值微分外推通过

三次样条求导

Episode 5 线性方程组

前置知识

高斯消元

平凡根法

追赶法

向量范数

矩阵范数

矩阵误差分析

Episode 6 线性方程组的迭代解法

迭代法

迭代误差分析

定常迭代法

雅可比迭代

高斯-赛德尔迭代

SOR方法

共轭梯度法

Episode 7 非线性方程

二分法

不动点和迭代法

局部收敛性和收敛阶

埃特金加速

斯特芬森迭代法

牛顿法

牛顿下山法

重根牛顿法

弦截法

抛物线法

非线性方程组

Episode 8

Episode 9 常微分方程

一阶常微分方程的初值问题

单步法

欧拉法

改进欧拉法

龙格库塔方法

线性多步法

预测-校正方法

收敛性-稳定性-相容性

一阶方程组

高阶方程组

刚性问题

Episode 1 引论

数值问题

数值问题其实可以离散输入，离散输出的问题。

误差

有绝对误差、相对误差，还有绝对误差限，相对误差限。

还有一些相加减乘除的误差。

有效数字

保持四舍五入之后，相对误差保持有效数字的半位的概念。

可以注意到“有效数字位数”并不是封闭的。也就是每一步都保证有效数字位数，最后的有效数字位数还是会改变，所以这个东西其实很没用。

病态问题

离散输入离散输出的问题可以表示成 $f(x)$ ，若 x 微微干扰，引起结果很大变化，则称为病态。

可以通过计算：

$$C_p = \left| \frac{f(x + \delta) - f(x)}{f(x)} \right| / \left| \frac{\delta}{x} \right| \approx \left| \frac{x f'(x)}{f(x)} \right|$$

来估计。

不稳定是指误差会一直变大。（实际上是不一样的概念）

技巧

引入了迭代法，松弛法等。

松弛法是根据两个近似解 x_0, x_1 ，用 $x_0 + \omega(x_1 - x_0)$ 逼近，原理不明（类似梯度？）。

Episode 2 插值

多项式插值

归根到底是线性方程组一定有唯一解。

拉格朗日插值

自然的用拉格朗日基逼近。

牛顿插值

引入均差。

引入差分算子和位移算子之后，均差还可以很方便的证明泰勒展开。

三次埃尔米特插值

为了插值更好的性质，拟合点的导数。

分为两种情况：

1. $f(x_0), f(x_1), f(x_2), f'(x_1)$
2. $f(x_0), f(x_1), f'(x_0), f'(x_1)$

分段插值

分段可以简单的线性插值，也可以利用上面的两点和两点导数埃尔米特插值来分段插值，使得导数也连续。

三次样条插值

目标是让二阶导也连续。

注意到分段埃尔米特插值中，一阶导是任意的，直观理解上，还有非常多“自由量”，可以通过线性方程组来使得二阶导连续。

Episode 3 逼近与拟合

线性空间

定义了线性空间。

并引出了内积空间和赋范空间。

内积空间显然蕴含赋范空间。

同时分成了 $\mathbb{R}^n$, $C[a, b]$ 两种线性空间。

内积还带上了权。

正交多项式

似乎：对于一样的权函数 $\rho(x)$ ，和一样的区间 $[a, b]$ ，多项式空间构成的**规范**正交多项式族是唯一的。

根据不同的权函数 $\rho(x)$ ，和不同的区间，通过施密特正交化方法，可以引出不同的正交多项式。

对于 $[-1, 1]$, $\rho(t) = 1$ 引出勒让德多项式，这也是最佳平方逼近多项式。

对于 $[-1, 1]$, $\rho(t) = \frac{1}{\sqrt{1-t^2}}$ 引出切比雪夫多项式，这也是最佳一致逼近多项式。（通过切比雪夫零点来插值，就不会出现龙格现象）。

对应的可以引出第二类切比雪夫多项式、拉盖尔多项式、埃尔米特多项式。

逼近

在一个多项式空间中逼近某个函数。

通常只考虑有限维多项式空间。

通过多元函数求导，可以引出Gram矩阵，而Gram矩阵的非奇异性又和线性无关等价。直接解即可。

当然，通过正交多项式，就更简单了，直接利用传统最小二乘法即可。对于不是标准区间的，只需要定义域变换即可。

拟合

在一个多项式空间中用多项式逼近若干个点。

其实就是从 $C[a, b]$ 来到了 $\mathbb{R}^n$

这时候的Gram矩阵的非奇异性和多项式在多项式空间的线性无关不等价了。（当然，和多项式在 $\mathbb{R}^n$ 的点值线性无关还是等价的。）

于是就要额外引入Harr条件（Harr条件还不懂）

有理逼近、帕得逼近

-

Episode 4 数值微分和数值积分

机械求积

在被积区间选取某些节点，根据这些节点计算积分。

形式为：

$$\int_a^b f(x) \rightarrow \sum_{k=0}^n A_k f(x_k)$$

代数精度

对于 m 次多项式能准确积分的方法称为具有 m 次代数精度。

插值形求积公式

为了保证代数精度，我们其实可以对被积区间插值，然后积分插值出来的函数。

$$I = \sum A_k f(x_k)$$
$$A_k = \int_a^b l_k(x) dx$$

可以证明 $I \rightarrow I^*$

$A_k > 0$ 时，公式稳定。

牛顿-柯特斯公式

选取等长节点的插值形求积公式被称为牛顿-柯特斯公式。并且这个时候 A_k 会是一个简单的多项式积分。

并且偶阶有额外的1代数精度，也就是 $n + 1$ 阶。

但 $n \geq 8$ 时不稳定。

复合求积公式

把上面的公式套用到分段积分上。

梯形法递推化

在复合梯形法的基础上：

$$\begin{aligned}T_n &= \frac{h}{2} \sum_{k=0}^{n-1} [f(x_k) + f(x_{k+1})] \\T_{2n} &= \frac{h}{4} \sum_{k=0}^{n-1} [f(x_k) + f(x_{k+1})] + \frac{h}{2} \sum_{k=0}^{n-1} f(x_{k+\frac{1}{2}}) \\T_{2n} &= \frac{1}{2} T_n + \frac{h}{2} \sum_{k=0}^{n-1} f(x_{k+\frac{1}{2}})\end{aligned}$$

外推技巧

记 $T(h) = T_n$

当被积函数 $f(x) \in C^\infty[a, b]$ ， $T(h)$ 可以写成 $I + a_1 h^2 + a_2 h^4 + \dots$

则 $T(\frac{h}{2}) = I + a_1 \frac{h^2}{4} + \dots$

则

$$S(h) = \frac{4T(\frac{h}{2}) - T(h)}{3} = I + b_1 h^4 + b_2 h^6 + \dots$$

的精度提升了。

可以继续令

$$\begin{aligned}C(h) &= \frac{16S(\frac{h}{2}) - S(h)}{15} \\R(h) &= \frac{64C(\frac{h}{2}) - C(h)}{63} \\&\dots\dots\dots\end{aligned}$$

不妨写成

$$T_m(h) = \frac{4^m T_{m-1}(\frac{h}{2}) - T_{m-1}(h)}{4^m - 1}$$

余项只有 $O(h^{2^{m+1}})$

由此引出隆龙贝格算法。

高斯求积公式

因为

$$\sum_{k=0}^n A_k f(x_k)$$

有 $2n + 2$ 个参数。

如果我们合理的选择参数，可能会拥有 $2n + 1$ 的代数精度。

高斯不限于此，他研究了带权 $\rho(x)$ 积分。

通过分析余项，可以知道当还是选用插值型函数时，

余项

$$R[f] = \frac{1}{(n+1)!} \int_a^b f^{(n+1)}(x) (\xi(x)) \omega_{n+1}(x) \rho(x) dx$$

发现我们只要选择插值节点，使得任意 $H_n(x)$ 和 $\omega_{n+1}(x)$ 在带权内积下正交即可，这不就选正交多项式吗！

高斯-勒让德求积公式

当 $\rho(x) = 1$, 区间为 $[-1, 1]$ 时, 对应的正交多项式为勒让德多项式。

对应还有高斯-切比雪夫求积公式、高斯-拉盖尔求积公式。

多重积分

化成累次积分再分步数值积分

数值微分

通过泰勒展开可以容易推导简单的前后向和中点公式。

但因为最后是形如 $\frac{f}{h}$ 的, 所以 h 变小的时候, 舍入误差变大, 故病态。

插值型求导公式

求插值出的多项式的导数。

可以推出如三点公式啥的。

数值微分外推通过

也可以外推, 不过当 h 过小的时候, 就会导致病态。

三次样条求导

因为三次样条导数的性质比较好, 所以也可以直接用这个求导

Episode 5 线性方程组

前置知识

详见LADR和artin的algebra。(还没写呢)

特征值: $\lambda : Ax = \lambda x$, 谱和谱半径: $\sigma(A) = \{\lambda\}, \rho(A) = \max\{\lambda\}$

特征多项式:

$$p(\lambda) = \det(\lambda I - A), \det A = \prod_{p(x)=0} x, \text{trace} A = \sum_{p(x)=0} x$$

Jordan型。

埃尔米特矩阵: $A \in \mathbb{C}^{m \times n}, A = \overline{A}^T$

自伴矩阵/酉矩阵: $A \in \mathbb{C}^{m \times n}, A^{-1} = \overline{A}^T$

正交矩阵: $A^{-1} = A^T$

对称矩阵: $A^T = A$

正定矩阵: $(Ax, x) = 0$

高斯消元

行变换 $[A|b]$ 使得变成对角或者上三角矩阵。

从而可以引出LU分解: $L^{-1}PA = U \iff PA = LU$.

然后 $PAx = LUx = b$ 是容易解决的

平凡根法

对于正定矩阵: $A = LU = LDU_0, A^T = U_0^T DL^T$

由分解唯一性: $U_0^T = L$, 则 $A = LDL^T = (LD^{\frac{1}{2}})(LD^{\frac{1}{2}})^T = L_1 L_1^T$

和LU分解类似可以求解方程组, 但是性质更好。

追赶法

-

向量范数

$$|x| \geq 0, |\alpha x| = |\alpha||x|, |x + y| \leq |x| + |y|$$

p 范数指幂 p 平均

可以证明 $N(x)$ 连续, 并且在有限维空间对于两种范数

$$\exists c_1, c_2 > 0, \forall x, c_1 |x|_1 \leq |x|_2 \leq c_2 |x|_1$$

这说明: 不同范数之间: 范数收敛是等价的。

矩阵范数

矩阵范数好像只考虑实向量空间。

$$|A| \geq 0, |\alpha A| = |\alpha||A|, |A+B| \leq |A| + |B|, |AB| \leq |A||B|$$

条件很苛刻。

特别地，如果 $|Ax| \leq |A||x|$ ，称为相容范数，容易注意到对相容范数 $\rho(A) \leq |A|$ 。

于是还直接定义了算子/从属范数，基于向量范数：

$$|A| = \max_{|x|=1} |Ax|$$

算子范数直接满足上面的条件，还相容。

所以行范数、列范数、谱范数都可以转化成证明他们是算子范数。

可以证明一定存在算子范数使得 $|A| \leq \rho(A) + \epsilon$

矩阵误差分析

-

Episode 6 线性方程组的迭代解法

主要是解决稀疏矩阵的求解。

迭代法

$$\begin{aligned}x^* &= Bx^* + f \\x^{(k+1)} &= Bx^{(k)} + f \\e^{(k)} &= x^{(k)} - x^* \\e^{(k+1)} &= Be^{(k)}\end{aligned}$$

则收敛等价于

$$\begin{aligned}e^k \rightarrow 0 &\iff B^k \rightarrow 0 \iff |B^k| \rightarrow 0 \iff \\&\rho(B) < 1 \iff |B|_s < 1\end{aligned}$$

其中 $\|\cdot\|_s$ 是从属范数。

还可以证明对任意范数： $|B^k|^{\frac{1}{k}} = \rho(B)$

迭代误差分析

若存在算子范数 $|B| = q < 1$

则有如下分析误差的方法：

$$\begin{aligned} 1. |x^* - x^{(k)}| &\leq q^k |x^* - x^{(0)}| \\ 2. |x^{(k+1)} - x^{(k)}| &\geq |x^* - x^{(k)}| - |x^* - x^{(k+1)}| \\ &\geq (1 - q) |x^* - x^{(k)}| \\ \iff |x^* - x^{(k)}| &\leq \frac{q}{1 - q} |x^{(k)} - x^{(k-1)}| \leq \frac{q^k}{1 - q} |x^{(1)} - x^{(0)}| \end{aligned}$$

这对于大部分的迭代误差分析都是有用的。

其中第一条用不到，因为不知道真正的 x^* 。

第二条可以用于事前分析和事后分析。

记平均收敛速度为： $R_k(B) = -\ln |B^k|^{\frac{1}{k}}, R(B) = -\ln \rho(B)$

定常迭代法

$$\begin{aligned} Ax &= b \\ A &= M - N \\ Mx &= Nx + b \\ x &= M^{-1}Nx + M^{-1}b \end{aligned}$$

所以只需要简单的找点非奇异的 M 即可。

最简单的令 $M = I$ 即可

雅可比迭代

令 $A = D + L + U, M = D$

高斯-赛德尔迭代

令 $M = D + L$

上面两种方法的收敛性都和对角占优： $|a_{i,i}| > \sum_{j \neq i} |a_{i,j}|$ 与矩阵 A 的可约性有关。

SOR方法

选择松弛因子 ω , 令 $M = \frac{1}{\omega}(D - \omega L)$

这是高斯赛德尔迭代的改进。

设由 x_0 高斯赛德尔迭代的结果为 x_1

则这里算的就是 $x_0 + \omega(x_1 - x_0)$

可以证明必要条件是 $0 < \omega < 2$ 。

共轭梯度法

-

Episode 7 非线性方程

二分法

利用连续函数的性质，可以找到区间里的一个根。

不动点和迭代法

若

$$\begin{aligned}\varphi(x) &\in C[a, b] \\ a &\leq \varphi(x) \leq b \\ |\varphi(x) - \varphi(y)| &\leq L|x - y|, 0 < L < 1\end{aligned}$$

则存在唯一不动点。最后一个条件是Lipschitz条件的基础上要求 $L < 1$ ，这个条件是收敛的充分条件。

这里也有

$$x_{k+1} = \varphi(x_k)$$

$$|x_{k+1} - x_k| = |\varphi(x_k) - \varphi(x_{k-1})| \leq L|x_k - x_{k-1}|$$

就变得和线性方程组的迭代法一样了，得到的结论同样是：

$$|x_k - x^*| \leq \frac{L}{1-L} |x_k - x_{k-1}| \leq \frac{L^k}{1-L} |x_1 - x_0|$$

局部收敛性和收敛阶

若在某局部有 $\varphi'(x) \leq L < 1$ ，则迭代法局部收敛。

因为

$$\varphi(x_k) = \varphi(x^*) + \sum \frac{\varphi^{(p)}(\xi)}{p!} (x_k - x^*)^p$$

$$\Rightarrow x_{k+1} - x^* = \sum \frac{\varphi^{(p)}(\xi)}{p!} (x_k - x^*)^p$$

所以我们可以定义 p 阶收敛阶：

$$\frac{e_{k+1}}{e_k^p} \rightarrow C$$

若 $\varphi^{(1)}(x) = 0, \varphi^{(2)}(x) = 0, \dots, \varphi^{(p)}(x) \neq 0$ ，则显然 φ 具有 p 阶收敛阶。

埃特金加速

将迭代看成一个线性函数：

$$x_1 - x^* = \varphi'(\xi)(x_0 - x^*) \approx L(x_0 - x^*)$$

$$x_2 - x^* \approx L(x_1 - x^*)$$

$$\frac{x_1 - x^*}{x_2 - x^*} \approx \frac{x_0 - x^*}{x_1 - x^*}$$

可以解得：

$$x^* \approx \frac{x_0 x_2 - x_1^2}{x_2 - 2x_1 + x_0}$$

用上面的式子迭代就可以加速。

斯特芬森迭代法

上面的过程中我们并不知道 L 的具体数值。

我们把再用另外一个东西去拟合 L 。

$$y_k = \varphi(x_k), z_k = \varphi(y_k) \\ \epsilon(x_k) = y_k - x_k, \epsilon(y_k) = z_k - y_k$$

我们把 $(x_k, \epsilon(x_k)), (y_k, \epsilon(y_k))$ 当成线性函数，找到不动点。

$$\begin{aligned} \epsilon(x_k) + \frac{\epsilon(y_k) - \epsilon(x_k)}{y_k - x_k}(x_{k+1} - x_k) &= 0 \\ \Rightarrow x_{k+1} &= x_k - \frac{\epsilon(x_k)}{\epsilon(y_k) - \epsilon(x_k)}(y_k - x_k) \\ &= x_k - \frac{(y_k - x_k)^2}{z_k - 2y_k + x_k} \end{aligned}$$

这个东西会比直接迭代高一个收敛阶。

牛顿法

$$f(x) \approx f(x_k) + f'(x_k)(x - x_k) \\ x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

简化牛顿法直接用 $f'(x_0)$ 代替 $f'(x_k)$

因为 $\varphi'(x) = \frac{f(x)f''(x)}{[f'(x)]^2}$ ，如果单根 $\rightarrow f'(x) \neq 0$ 则是平方收敛的。

牛顿下山法

牛顿法不一定收敛。

我们强制一个要求 $|f(x_{k+1})| < |f(x_k)|$

然后再加上一个： $x_{k+1} = x_k - \lambda \frac{f(x_k)}{f'(x_k)}$

重根牛顿法

这时不是单根，则 $f'(x) = 0$

就有

$$\varphi(x^*) = 1 - \frac{1}{m}$$

所以修改迭代函数：

$$x_{k+1} = x_k - m \frac{f(x_k)}{f'(x_k)}$$

则还是平方收敛的。

或者直接对新的函数 $\mu(x) = \frac{f(x)}{f'(x)}$ 使用牛顿法，就变成单根了。

弦截法

在 $f'(x)$ 不好求的时候，我们用差商： $\frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}$ 代替 $f'(x)$ ，就得到弦截法。

抛物线法

用 x_{k-2}, x_{k-1}, x_k 3点拟合一个二次函数，然后用二次函数的零点去迭代，其中选择离 x_k 比较近的那个。

非线性方程组

-

Episode 8

-

Episode 9 常微分方程

一阶常微分方程的初值问题

$$\begin{aligned}y' &= f(x, y), x \in [x_0, b] \\ y(x_0) &= y_0\end{aligned}$$

关于 y 的Lipschitz条件: $f(x, y_1) - f(x, y_2) \leq L|y_1 - y_2|$

由ode理论可知, 满足上面条件的问题存在唯一可微解。

单步法

$$\begin{aligned}y_{n+1} &= y_n + h\varphi(x_n, y_n, y_{n+1}, h) \\ x_{n+1} &= x_n + h\end{aligned}$$

从而迭代的解决问题。

若 φ 中含有 y_{n+1} 的项, 则称为隐式方法, 不然称为显示方法。

局部截断误差则是假设之前的步骤没有误差, 考虑一步的误差, 也就是

$$T_{n+1} = y(x_n + h) - y_{n+1}$$

(隐式方法的定义其实需要更精细的讨论)

则关于 h 同样分为 p 阶精度。

欧拉法

$$\begin{aligned}1. & y_{n+1} = y_n + hf(x_n, y_n) \\ 2. & y_{n+1} = y_n + hf(x_{n+1}, y_{n+1}) \\ & y_{n+1}^0 = y_n + hf(x_n, y_n) \\ & y_{n+1}^1 = y_n + hf(x_n, y_{n+1}^0) \\ & \dots \\ & y_{n+1}^k \rightarrow y_{n+1}, (hL < 1) \\ 3. & y_{n+1} = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, y_{n+1})] \\ & \dots \\ & (hL < 2)\end{aligned}$$

分别为欧拉法, 后向欧拉法, 和梯形法。后两种是隐式方法, 需要迭代。

改进欧拉法

预测校正思想，上面隐式方法的太麻烦了。

先算一个，然后当成对的：

$$\begin{aligned}\bar{y}_{n+1} &= y_n + hf(x_n, y_n) \\ y_{n+1} &= y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, \bar{y}_{n+1})]\end{aligned}$$

其实就是梯形方法只进行一次。

龙格库塔方法

考虑显示的龙格库塔方法：

$$\begin{aligned}y_{n+1} &= y_n + h\varphi(x_n, y_n, h) \\ \varphi(x_n, y_n, h) &= \sum_{i=1}^r c_i K_i \\ K_1 &= f(x_n, y_n) \\ K_i &= f(x_n + \lambda_i h, y_n + h \sum_{j=1}^{i-1} \mu_{i,j} K_j)\end{aligned}$$

其中 r 个点代表 r 阶龙格库塔方法。

可以根据局部截断误差的阶来列方程组解出2, 3, 4阶龙格库塔方法。

线性多步法

龙格库塔方法只用到了 y_n ，线性多步法的想法是利用更多的 $y_{n-1}, \dots$

$$y_{n+k} = \sum_{i=0}^{k-1} \alpha_i y_{n+i} + h \sum_{i=0}^k \beta_i f(x_{n+i}, y_{n+i})$$

$\beta_k = 0$ 表示显式方法，否则是隐式方法。

同样，通过分析局部截断误差的阶可以推导出阿当姆斯显式和隐式公式（ $\alpha_{k-1} = 1$ 其他等于0），还可以推出米尼尔方法（ $k = 4, \alpha_0 = 1$ ，其他 α 等于0），辛普森方法（ $k = 2, \alpha_0 = 1$ ，其他 α 等于0），汉明方法。

预测-校正方法

因为隐式公式需要迭代，计算量较大，我们直接用一个同阶的显式公式推出 $f(x_{n+k}, y_{n+k})$ ，然后直接计算。

进一步更复杂的有修正-预测-校正格式

收敛性-稳定性-相容性

-

一阶方程组

把 y 和 f 都看成向量。

则 $y'_i = f_i(x, y_1, y_2, \dots, y_N)$

然后直接应用上面的公式也是可以的。

高阶方程组

$$y^{(m)} = f(x, y, y', \dots, y^{(m-1)})$$

可以转化成

$$\begin{aligned} y_1 &= y, y_2 = y', \dots, y_m = y^{(m-1)} \\ f_1 &= y_2, f_2 = y_3, \dots, f_m = f(x, y, y_1, \dots, y_m) \end{aligned}$$

就变成一阶方程组了。

刚性问题

两个差别很大的分量，一个分量需要低步长，一个分量需要高区间长度。

这就导致问题变得困难。